

Err and err and err again, but less and less and less.

Aula 15

Forma normal de Chomsky

Há muitas situações em que, seja para facilitar uma demonstração, ou para aplicar um algoritmo, a transformação de uma CFG numa outra em que todas as suas produções estão normalizadas é de primordial importância. Uma dessas **formas normais** é a chamada **Forma Normal de Chomsky**.

Simplificação de gramáticas

Dada uma CFG podemos tentar simplificá-la eliminando os símbolos que nunca derivam qualquer símbolo terminal nem ϵ , ou seja os símbolos inúteis. Isto pode ser feito, percorrendo a árvore da gramática, de forma ascendente (*bottom-up*), partindo das produções que são constituídas integralmente por símbolos terminais ou por ϵ . O lema seguinte explicita este facto assim como o procedimento a tomar, na sua demonstração.

Lema

Dada uma CFG $G = \langle V, \Sigma, P, S \rangle$, representando uma linguagem não vazia, podemos encontrar uma gramática $G' = \langle V', \Sigma, P', S \rangle$ em que,

$$((\forall A \in V')(\exists w \in \Sigma^*) A \Rightarrow_{G'}^* w).$$

Demonstração: Todos os símbolos não terminais $A \in V$ para os quais existe uma produção da forma $A \rightarrow w$, para alguma palavra $w \in \Sigma^*$, têm claramente lugar em V' . Se a produção $A \rightarrow X_1 X_2 \cdots X_n$ existe em P , com os X_i símbolos terminais ou outros símbolos não terminais que já se encontrem incluídos em V' , isso faz com que possamos incluir A em V' também. O conjunto V' pode ser obtido como o fecho do processo atrás descrito. Depois de obtido V' podemos remover de P todas as produções em que tomem lugar símbolos não terminais não constantes de V' , obtendo assim P' . $\square$

Podemos prosseguir na simplificação de uma CFG eliminando todos os símbolos que não sejam atingíveis a partir do símbolo inicial. Agora basta percorrer a árvore da gramática, de forma descendente (*top-down*), partindo do símbolo inicial.

Lema

Dada uma CFG $G = \langle V, \Sigma, P, S \rangle$ podemos encontrar uma gramática equivalente $G' = \langle V', \Sigma', P', S \rangle$ tal que para cada $X \in V' \cup \Sigma'$ existem $\alpha, \beta \in (V' \cup \Sigma')^*$ tal que $S \Rightarrow^* \alpha X \beta$.

Demonstração: O conjunto $V' \cup \Sigma$, pode ser construído por um processo iterativo. Colocamos, primeiramente, S em V' . Se A é colocado em V' e $A \rightarrow \alpha_1 \mid \alpha_2 \mid \cdots \mid \alpha_n$, então adicionamos todas as variáveis de

$\alpha_1, \alpha_2, \dots, \alpha_n$ a V' , assim como adicionamos os terminais de $\alpha_1, \alpha_2, \dots, \alpha_n$ a Σ' . P' é o conjunto das produções que contêm símbolos somente de $V' \cup \Sigma'$. $\square$

Exemplo.

Consideremos a seguinte gramática:

$$\begin{aligned} S &\rightarrow ASA \mid aB \mid C \mid AS, \\ A &\rightarrow B \mid S, \\ B &\rightarrow ab \mid b \mid \varepsilon, \\ C &\rightarrow CB \mid DC, \\ D &\rightarrow DC \mid DB, \\ E &\rightarrow a \mid Aa \mid Ca. \end{aligned}$$

Começemos por eliminar os símbolos não atingíveis. Como S refere A , B e C , estes são atingíveis. Por sua vez C refere D . O conjunto de símbolos atingíveis é então

$$\{S, A, B, C, D\}.$$

E é o único símbolo não atingível e que pode ser eliminado com todas as suas produções. A gramática resultante é, então

$$\begin{aligned} S &\rightarrow ASA \mid aB \mid C \mid AS, \\ A &\rightarrow B \mid S, \\ B &\rightarrow ab \mid b \mid \varepsilon, \\ C &\rightarrow CB \mid DC, \\ D &\rightarrow DC \mid DB. \end{aligned}$$

Agora queremos eliminar os símbolos inúteis. Então começemos por “marcar” os símbolos que têm alguma produção inteiramente composta por símbolos terminais ou por ε . Está nestas condições somente o B . Mas com o B “marcado”, A tem uma produção inteiramente “marcada”, $A \rightarrow B$, assim como S , $S \rightarrow aB$. Os símbolos úteis são, assim,

$$\{S, A, B\}.$$

Os restantes símbolos, C e D , podem ser eliminados. A gramática resultante desta simplificação é:

$$\begin{aligned} S &\rightarrow ASA \mid aB \mid AS, \\ A &\rightarrow B \mid S, \\ B &\rightarrow ab \mid b \mid \varepsilon, \end{aligned}$$

CNF

Para muitas das demonstrações sobre as CFL que assentam sobre a sua representação por uma CFG é conveniente apresentar esta última sob uma forma binária. Essa forma é a chamada Forma Normal de Chomsky em que a gramática tem somente

produções da forma

$$A \rightarrow BC$$

em que B e C são símbolos não terminais; ou da forma

$$A \rightarrow a$$

em que a é um símbolo terminal. Se S for o símbolo inicial, poderá haver uma produção da forma

$$S \rightarrow \varepsilon$$

mas então nenhuma produção da gramática pode conter S no seu lado direito.

Teorema

Qualquer linguagem independente do contexto admite uma gramática que a gera e que se encontra na Forma Normal de Chomsky (CNF), ou seja, todas as suas produções são da forma $A \rightarrow BC$ ou $A \rightarrow a$ com A, B, C símbolos não terminais e a símbolo terminal, com uma eventual produção $S \rightarrow \varepsilon$ se S for o símbolo inicial e não ocorrer no lado direito de qualquer outra produção da gramática.

Demonstração: Seja $G = \langle V, \Sigma, P, S \rangle$ uma CFG já depurada de símbolos inúteis ou não atingíveis. Começamos por introduzir um novo símbolo não terminal S' , fazemo-lo o novo símbolo inicial e acrescentamos uma produção $S' \rightarrow S$, sendo S o símbolo inicial original. Isto garante que o símbolo inicial não ocorre em nenhum membro direito de uma produção da gramática. A gramática resultante é trivialmente equivalente à original.

Seguidamente eliminamos todas as produções- ε não iniciais, ou seja toda as produções do tipo $A \rightarrow \varepsilon$, em que $A \in V$ e A não inicial. Para tal procedemos da forma seguinte. Para cada produção $A \rightarrow \varepsilon$ (com A não inicial), removemos tal produção e para todas as outras produções, por cada ocorrência do símbolo A no lado direito de uma produção ($R \rightarrow uAv$) acrescentamos uma produção em que essa ocorrência de A foi removida ($R \rightarrow uv$). Se a produção contiver somente A como membro direito da produção ($R \rightarrow A$) então acrescentamos uma produção- ε ($R \rightarrow \varepsilon$) a menos que essa produção já tivesse anteriormente sido alvo de remoção por este processo. É fácil ver que cada uma destas transformações preservam a linguagem definida pela gramática. No fim obtemos uma gramática equivalente à inicial sem produções- ε , a menos de uma eventual produção- ε inicial.

Eliminam-se as produções unitárias. Para cada produção da forma $A \rightarrow B$, remove-se a produção da gramática e para cada produção $B \rightarrow u$ acrescenta-se uma produção $A \rightarrow u$, a menos que esta produção fosse uma que tivesse sido anteriormente removida por este processo. Estas transformações preservam a linguagem gerada pela gramática, pelo que no fim teremos uma gramática sem produções unitárias equivalente à gramática original.

Finalmente rescrevem-se as produções para o formato desejado. Para cada produção da forma $A \rightarrow u_1 u_2 \cdots u_k$, com $k \geq 3$ sendo os u_i símbolos não terminais ou símbolos terminais, substitui-se pelas produções

$$A \rightarrow u_1 A_1, A_1 \rightarrow u_2 A_2, \dots, A_{k-2} \rightarrow u_{k-1} u_k,$$

com A_i novos símbolos não terminais. Para cada $u_i \in \Sigma$, substituímos u_i por um novo símbolo não terminal U_i e acrescentamos a produção $U_i \rightarrow u_i$. Mais uma vez, cada uma destas transformações preserva a linguagem aceite pela gramática, pelo que no fim do processo temos uma gramática equivalente à original, na Forma Normal de Chomsky. $\square$

Exemplo.

Consideremos a gramática seguinte, e utilizemos o processo descrito na demonstração anterior para obter uma gramática equivalente, na Forma Normal de Chomsky

$$\begin{aligned}
S &\rightarrow ASA \mid aB \mid AS \mid AB, \\
A &\rightarrow B \mid S, \\
B &\rightarrow ab \mid b \mid \varepsilon.
\end{aligned}$$

Introduzimos um novo símbolo inicial,

$$\begin{aligned}
\textcolor{red}{S}' &\rightarrow S \\
S &\rightarrow ASA \mid aB \mid AS \mid AB, \\
A &\rightarrow B \mid S, \\
B &\rightarrow ab \mid b \mid \varepsilon.
\end{aligned}$$

Eliminamos o ε

$$\begin{aligned}
S' &\rightarrow S \\
S &\rightarrow ASA \mid aB \mid AS \mid AB \mid a \mid A, \\
A &\rightarrow B \mid S \mid \varepsilon, \\
B &\rightarrow ab \mid b \mid \varepsilon.
\end{aligned}$$

Agora temos que eliminar o ε que acabamos de introduzir

$$\begin{aligned}
S' &\rightarrow S \\
S &\rightarrow ASA \mid aB \mid AS \mid AB \mid a \mid A \mid SA \mid \varepsilon, \\
A &\rightarrow B \mid S \mid \varepsilon, \\
B &\rightarrow ab \mid b.
\end{aligned}$$

Agora podemos eliminar o ε que ocorre na produção de S (acabado de introduzir)

$$\begin{aligned}
S' &\rightarrow S \mid \varepsilon \\
S &\rightarrow ASA \mid aB \mid AS \mid AB \mid a \mid A \mid SA \mid \varepsilon \mid AA, \\
A &\rightarrow B \mid S, \\
B &\rightarrow ab \mid b.
\end{aligned}$$

Nas produções de S ocorre um ε , mas, como a variável S' não ocorre no lado direito de nenhuma produção, esse ε vai representar somente a própria palavra ε , pelo que não constitui qualquer problema. Temos agora que eliminar as produções unitárias, ou seja as produções da forma $V_1 \rightarrow V_2$. Começemos por eliminar a produção $A \rightarrow B$, substituindo-a por todas as produções de B

$$\begin{aligned}
S' &\rightarrow S \mid \varepsilon \\
S &\rightarrow ASA \mid aB \mid AS \mid AB \mid a \mid A \mid SA \mid AA, \\
A &\rightarrow B \mid S \mid ab \mid b, \\
B &\rightarrow ab \mid b.
\end{aligned}$$

Fazemos o mesmo para a produção $S \rightarrow A$

$$S' \rightarrow S \mid \varepsilon$$

$$S \rightarrow ASA \mid aB \mid AS \mid AB \mid a \mid A \mid SA \mid AA \mid ab \mid b,$$

$$A \rightarrow S \mid ab \mid b,$$

$$B \rightarrow ab \mid b.$$

E, finalmente, temos que proceder da mesma forma para as produções $A \rightarrow S$ e $S' \rightarrow S$

$$S' \rightarrow S \mid \varepsilon \mid ASA \mid aB \mid AS \mid AB \mid a \mid SA \mid AA \mid ab \mid b$$

$$S \rightarrow ASA \mid aB \mid AS \mid AB \mid a \mid SA \mid AA \mid ab \mid b,$$

$$A \rightarrow S \mid ab \mid b \mid ASA \mid aB \mid AS \mid AB \mid a \mid SA \mid AA \mid ab \mid b,$$

$$B \rightarrow ab \mid b.$$

Introduzindo novas variáveis X_1 e X_2 , podemos substituir produções como $B \rightarrow ab$

$$S' \rightarrow \varepsilon \mid ASA \mid \textcolor{red}{X}_1 B \mid AS \mid AB \mid a \mid SA \mid AA \mid \textcolor{red}{X}_1 X_2 \mid b$$

$$S \rightarrow ASA \mid \textcolor{red}{X}_1 B \mid AS \mid AB \mid a \mid SA \mid AA \mid \textcolor{red}{X}_1 X_2 \mid b,$$

$$A \rightarrow \textcolor{red}{X}_1 X_2 \mid b \mid ASA \mid \textcolor{red}{X}_1 B \mid AS \mid AB \mid a \mid SA \mid AA,$$

$$B \rightarrow \textcolor{red}{X}_1 X_2 \mid b,$$

$$\textcolor{red}{X}_1 \rightarrow a,$$

$$\textcolor{red}{X}_2 \rightarrow b.$$

Agora só resta transformar as produções com mais do que três variáveis do lado direito, o que pode ser feito introduzindo uma nova variável Y_1

$$S' \rightarrow \varepsilon \mid \textcolor{red}{A} Y_1 \mid X_1 B \mid AS \mid AB \mid a \mid SA \mid AA \mid X_1 X_2 \mid b$$

$$S \rightarrow \textcolor{red}{A} Y_1 \mid X_1 B \mid AS \mid AB \mid a \mid SA \mid AA \mid X_1 X_2 \mid b,$$

$$A \rightarrow X_1 X_2 \mid b \mid \textcolor{red}{A} Y_1 \mid X_1 B \mid AS \mid AB \mid a \mid SA \mid AA,$$

$$B \rightarrow X_1 X_2 \mid b,$$

$$X_1 \rightarrow a,$$

$$X_2 \rightarrow b,$$

$$\textcolor{red}{Y}_1 \rightarrow SA.$$

O resultado é, portanto, uma gramática na sua forma normal de Chomsky, equivalente à gramática original.

Rogério Reis